Recommendersysteme

- Matrixfaktorisierungs-Recommender

Recommendersysteme: Netflix

- Netflix competition

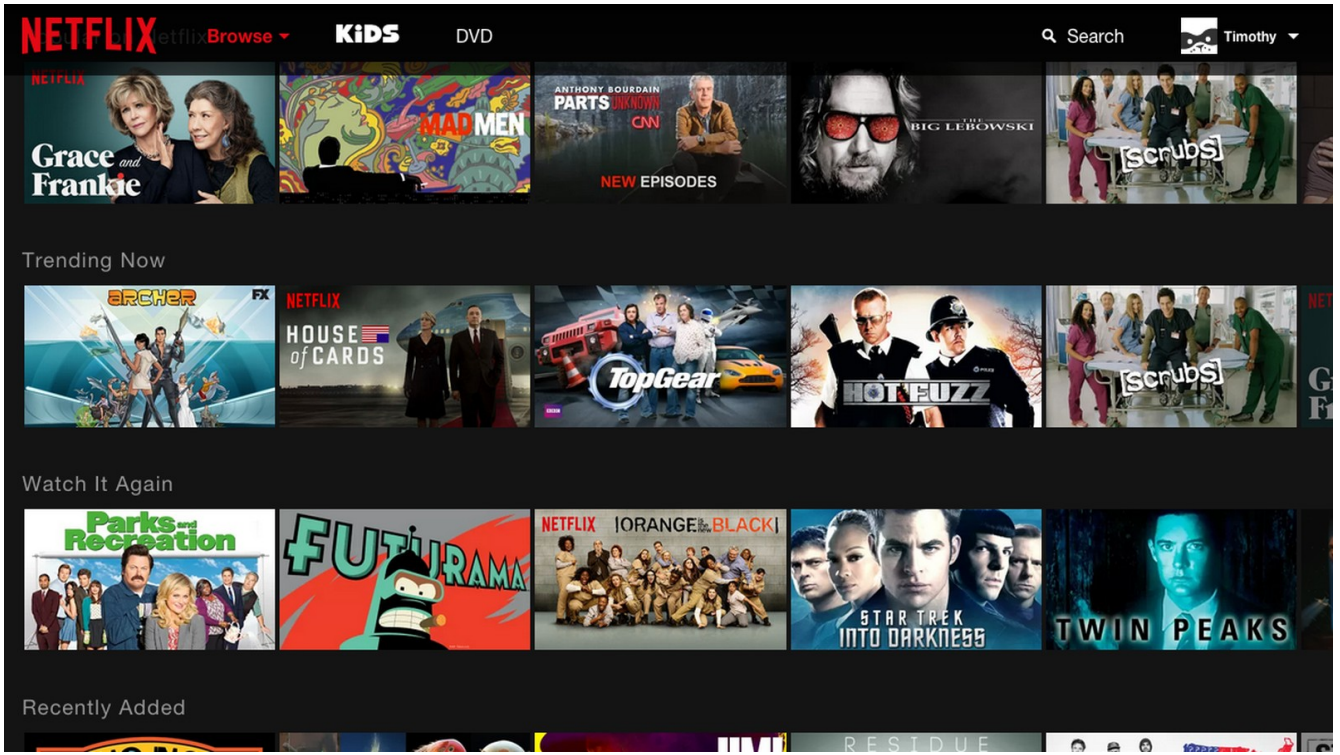

Recommendersysteme: Netflix

- Netflix competition 2009

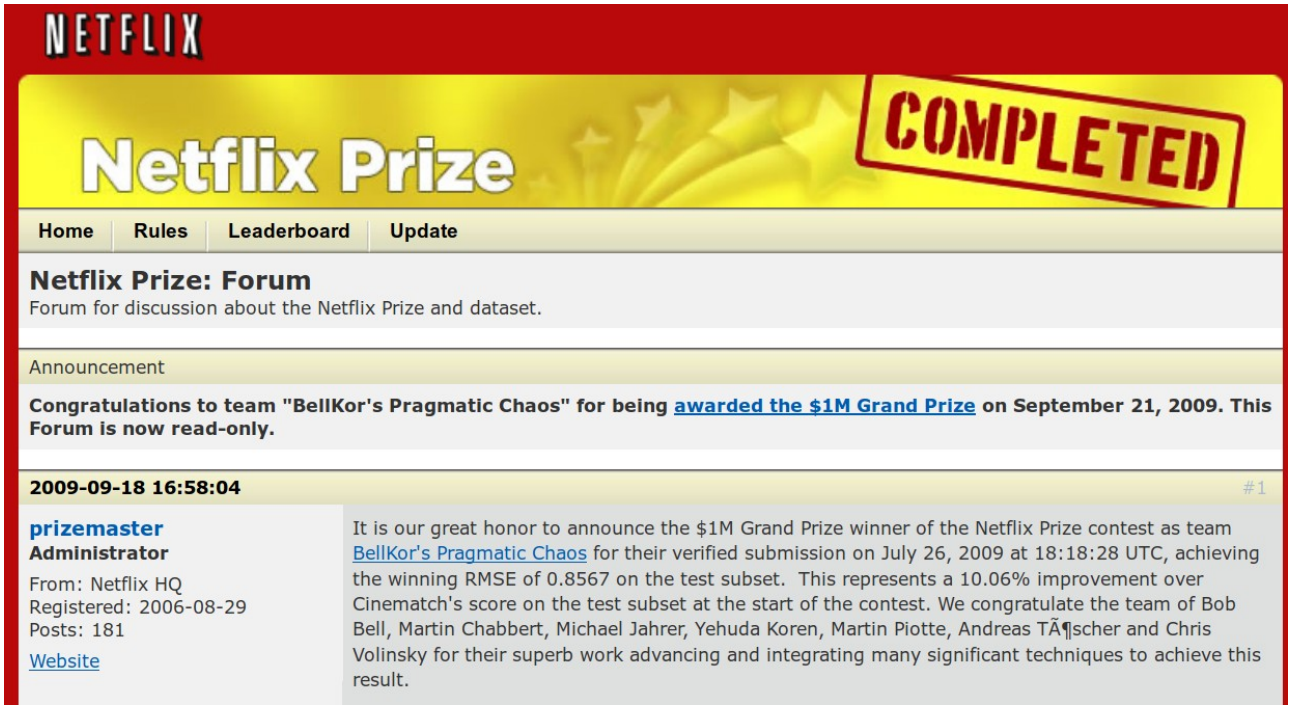

Recommendersysteme: Amazon

- Produktempfehlungen:

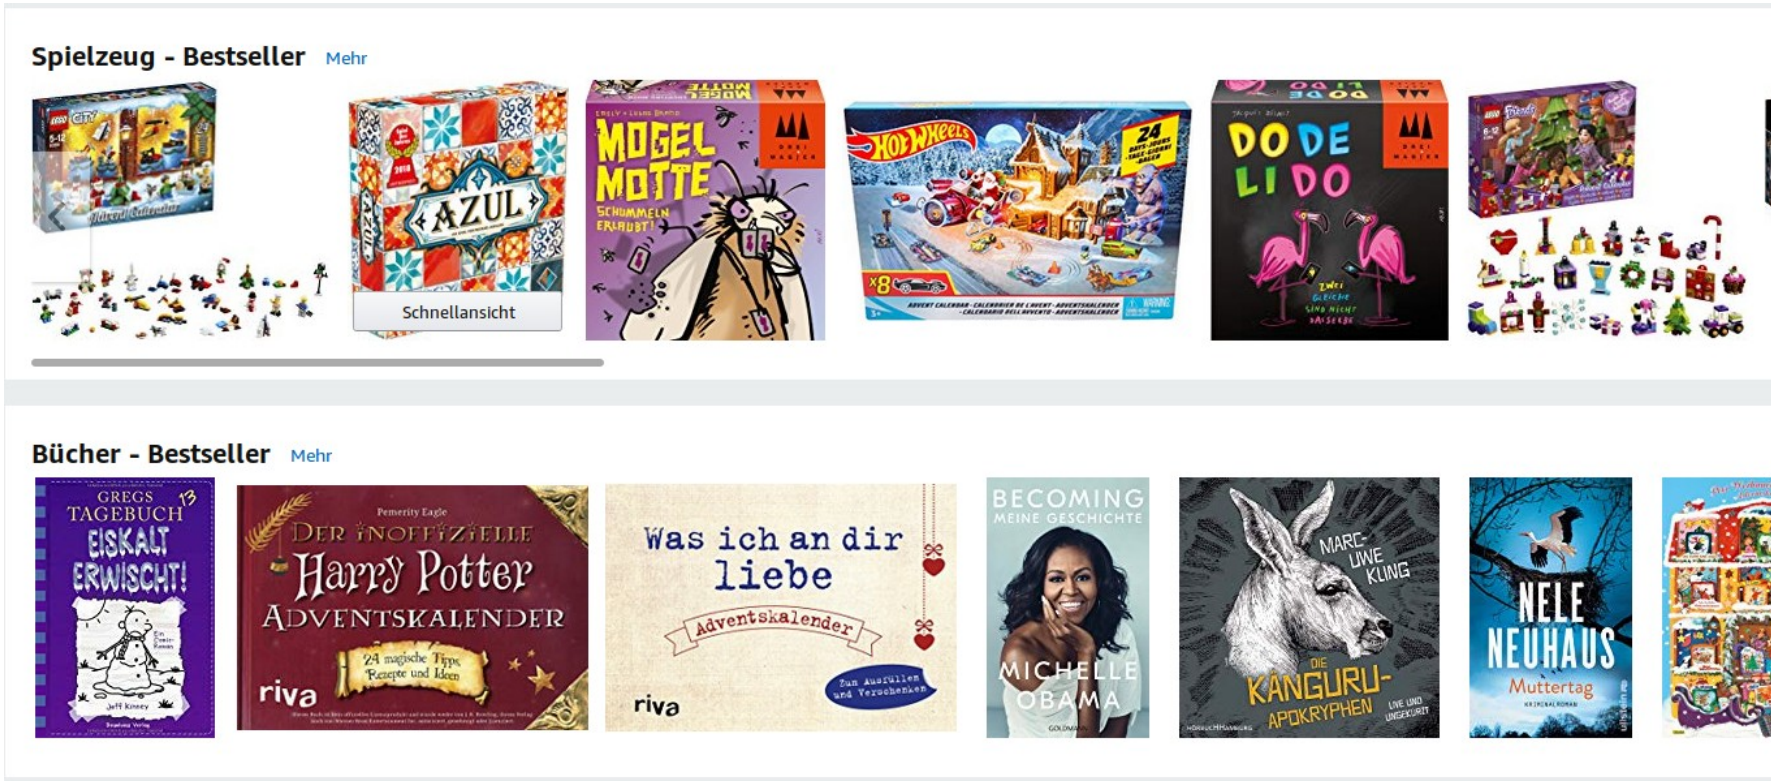

Recommendersysteme: Social Media

- Produktempfehlungen
- Newsempfehlungen

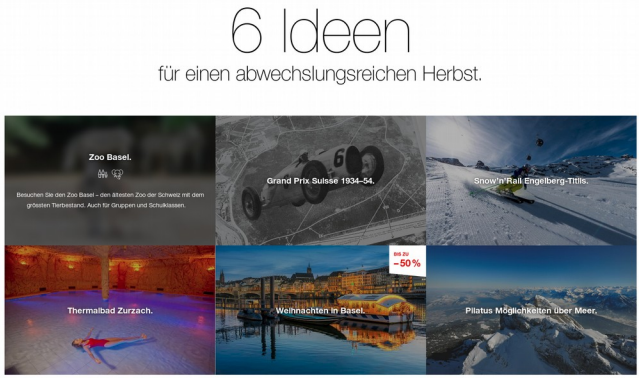

Was ist das Ziel von Recommendersystemen?

- Etwas gegen „Information Overload“ tun:
  - 10^7-10^8 Bücher auf Amazon
  - Welche sind interessant für welchen Kunden?
- ↔ „Information Retrieval“: keine Suchabfrage des Users bekannt
- Ziel des Händlers: Umsatz steigern!
- Ziel formal: Wähle für jeden User k=5 Items aus ~10^6 Items, die ihm/ihr gefallen könnten
- Mögliche Zielformulierung: Gegeben eine Rating Matrix R mit Elementen r_{ui}
  Meint User u bewertet Item i mit Rating r_{ui} in 1,…,5
  Schätze ich die Ratings

$$\hat{r}_{ui} \sim r_{ui}$$

- In dieser Form ist es ein supervised ML Problem, aber mit besonderen Herausforderungen

Herausforderungen

- Sparsity: User-Item-Matrix ist **sparse**: Nur sehr wenige Einträge sind bekannt (einige 10ppm?)

$$R = \begin{pmatrix} ? & ? & \dots & 4 \\ 1 & ? & \dots & 0 \\ ? & 0 & \dots & 0 \end{pmatrix}$$

- Scalability:
  - ~10^6 Items (Bücher, Musikstücke, News,…)
  - ~10^6 User
  - Brauche für jeden User k empfohlene Elemente
- Value of Time: Trainings-Ratings aus der Vergangenheit!
  - Bildet dies die Wünsche des Users jetzt gut ab?
- Evaluation: Wie finde ich raus, ob ein Recommender gut ist?
  - Accuracy vs. Diversity ?
- Cold Start: Was tun wenn ich noch nichts über den Benutzer weiss?

Algorithmenklassen

- Wie sollen die Elemente ausgewählt werden? → Algorithmen
- Popularity Recommender: top-k
  - Keine Personalisierung!

- User-Ähnlichkeitsbasiert:
  - „Ähnliche Benutzer mögen ähnliche Items“?

$$\hat{r}_{ui} = \bar{r}_u + \lambda \sum_{v \in U_u} s_{uv} \left(r_{vi} - \bar{r}_v \right)$$

  - **Aufgabe: Was ist wohl** U_u **?**
  - **Aufgabe: Was ist wohl** $\bar{r}_v$ **?**
  - **Aufgabe**: Was tun, wenn nur implizite Ratings (gesehen oder nicht) verfügbar sind?

Algorithmenklassen 2

- Item-Ähnlichkeitsbasiert: „Benutzer mag ähnliche Items zu denen die er bisher mochte“?

$$\hat{r}_{ui} = \frac{\sum_{j \in I_u} s_{ij} r_{uj}}{\sum_{k \in I_u} |s_{ik}|}$$

- Dimensionsreduktion: Approximiere $R \sim \hat{R}$ mit nur wenigen Parametern
  - Matrixfaktorisierung
  - Singular-Value-Decomposition
- Diffusionsbasiert: Benutze Graph-Eigenschaften der Rating-matrix
  - Z.B. Google-Pagerank
- Social filtering: Benutzer empfehlen sich gegenseitig Items
- Hybride Ansätze: Kombiniere Recommendersysteme
- ...

Metriken zur Evaluation von RS

- Offline-Metriken: Benutze ein Trainingsset aus der Vergangenheit
- Fehlermasse wie im Machine Learning:

$$\mathrm{MAE} = \frac{1}{|E^P|} \sum_{(i,\alpha)\in E^P} |r_{i\alpha} - \tilde{r}_{i\alpha}|,$$

$$\mathrm{RMSE} = \left(\frac{1}{|E^P|} \sum_{(i,\alpha)\in E^P} (r_{i\alpha} - \tilde{r}_{i\alpha})^2\right)^{1/2}$$

- **Einwand**: Nur die Top-k Items sind wirklich relevant!
- Precision@k: Bruchteil der relevanten Items in den top-k
- Recall: Bruchteil der relevanten Items bzgl aller für den User relevanten Objekte
- Vergleiche z.B. mit Zufallsempfehlung
- Spearman rho, Kendall tau: Rangkorrelationsmetriken

Weitere Evaluationsmetriken

- Weitere Aspekte sind relevant und sollten quantifiziert werden
- Diversity: Vielseitigkeit der Empfehlungen

- Coverage: Wieviele Items kann der Recommender überhaupt empfehlen?
- Serendipity:
  - engl. „unerwartete Entdeckung“, „glücklicher Zufall“: serendipitous encounters
  - Finde Items die nicht nur relevant oder neu sind, sondern klar anders als bisher gesehenes
- ...

A survey of serendipity in recommender sys tems

D. Kotkov et al.

Matrixfaktorisierung

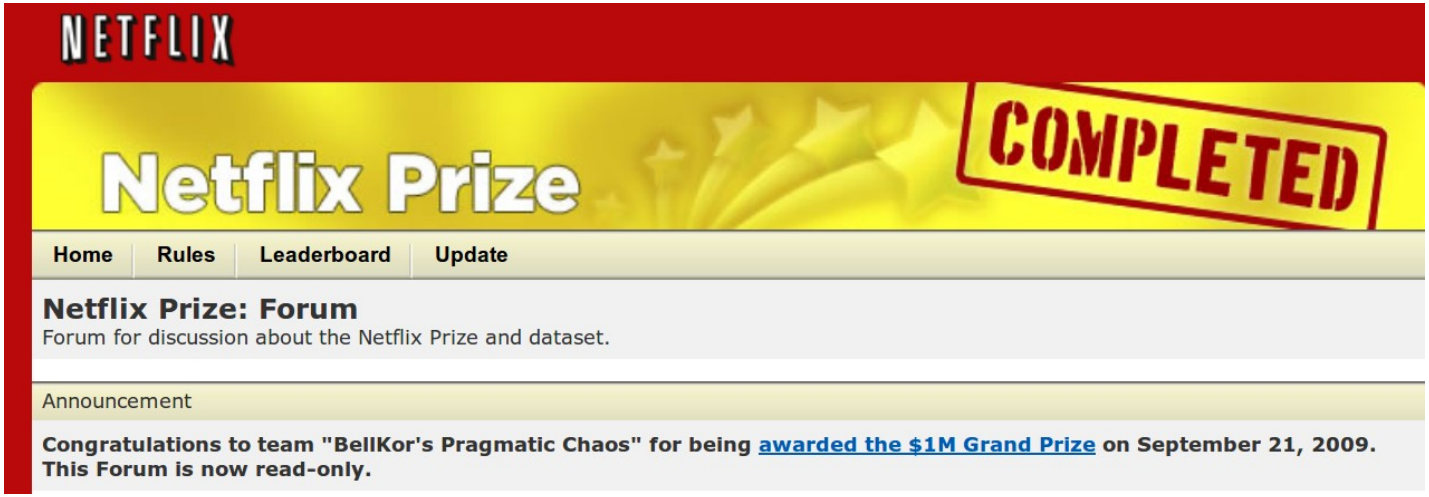

Matrixfaktorisierung

- Gewinner der Netflix Competition:
  Matrix-Faktorisierung als wichtige Komponente

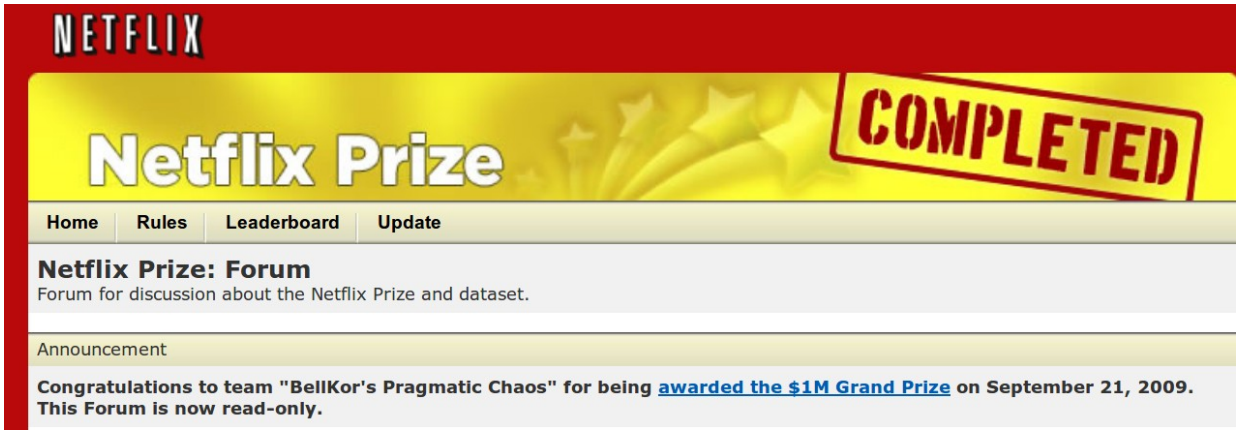

- „Baseline predictor“:

$$b_{ui} = \mu + b_u + \alpha_u \cdot \mathrm{dev}_u(t_{ui}) + b_{u,t_{ui}} + (b_i + b_{i,\mathrm{Bin}(t_{ui})}) \cdot c_u(t_{ui})$$

- Matrix Faktoris

$$\hat{r}_{ui} = b_{ui} + q_i^T \left(p_u(t_{ui}) + |\mathrm{N}(u)|^{-\frac{1}{2}} \sum_{j \in \mathrm{N}(u)} y_j \right)$$

Matrixfaktorisierung durch SVD

- SVD: Singulärwertzerlegung
- **Aufgabe:** Bearbeiten Sie das Notebook Matrix_Faktorisierung_SVD.ipynb
- Typischerweise haben wir sehr viel mehr Benutzer und Items als in diesem Ansatz.
- Wie geht das mit Big Data? Z.B. Hadoop MapReduce, Spark?
  - Hadoop/Spark: Charakterisiert durch viele unabhängige Nodes und ein eher langsames Netzwerk

Matrixfaktorisierung Theorie 1

- Modelliere Ratings (p_u und q_i sind Vektoren mit k Komponenten):

$$\hat{r}_{ui} = p_u^T q_i = \sum_{k=1}^{K} p_{uk} q_{ki}$$

- Idee: Beschreibe jedes Item und jeden User durch k Zahlen (z.B. k=5; nicht k=1000!)
  Latente Faktoren für User und Items:

$$\vec{p}_u = \begin{pmatrix} p_{u1} \\ p_{u2} \\ \vdots \\ p_{uk} \end{pmatrix} \qquad \vec{q}_i = \begin{pmatrix} q_{i1} \\ q_{i2} \\ \vdots \\ q_{ik} \end{pmatrix}$$

Matrixfaktorisierung Theorie 2

- Rating ist das Skalarprodukt

$$\hat{r}_{ui} = \vec{p}_u \cdot \vec{q}_i = p_{u1}q_{i1} + p_{u2}q_{i2} + \cdots + p_{uk}q_{ik}$$

- Die Matrix r wird so durch eine Matrix $\hat{r}$ mit Rang k bestmöglich angenähert.

MatrixMatrixfaktorisierung Theorie 3

- Modelliere Ratings:

$$\hat{r}_{ui} = p_u^T q_i = \sum_{k=1}^{K} p_{uk} q_{ki}$$

- Kostenfunktion mit Regularisierungstermen:

$$e^2 = \sum_{u,i} \left(r_{ui} - \hat{r}_{ui}\right)^2 + \lambda \sum_{u,k} p_{uk}^2 + \lambda \sum_{i,k} q_{ik}^2$$

- Minimiere $e^2(p,q)$

$$\frac{\partial}{\partial p} e^2(p,q) = 0$$

Matrixfaktorisierung Theorie 4

- Halte q konstant, variiere p: wo ist das Minimum?
- Ableitung:

$$0 = \frac{\partial}{\partial p_{uk}} e^2(p,q) = \dots$$

$$= -2q_{\bar{k}i}\left(r_{ui} - \sum_{m} p_{u\bar{m}} q_{\bar{m}i}\right) + 2\lambda p_{uk}$$

- Dies lässt sich nach p auflösen!

$$p_u = \left(\sum_{i':r_{ui'}\neq\emptyset} q_{i'}\, q_{i'}^T + \lambda 1_{k\times k}\right)^{-1} \sum_{i:r_{ui}\neq\emptyset} q_i r_{ui}$$

- Struktur: neues p = (k-mal-k Matrix)$^{-1}$ * (q_1 r_{u1}+q_2 ru2+…)
- Genau gleich, wenn p konstant und nach q abgeleitet wird

Kochrezept!

- Beispiel für k=5: p und q sind Vektoren mit 5 Komponenten
- Initialisiere beide mit zufälligen Werten
- Schritt 3: Gradientenabstieg: „Für alle Benutzer, rechne:“
- Stochastischer Gradientenabstieg: „Für einen zufälligen Benutzer, rechne:“
- Finde nun einen besseren Wert für den Latenten Faktor Vektor

$$p_u = \left(\sum_{i':r_{ui'} \neq \emptyset} q_{i'} q_{i'}^T + \lambda 1_{k \times k} \right)^{-1} \sum_{\bar{i}:r_{u\bar{i}} \neq \emptyset} q_{\bar{i}} r_{u\bar{i}}$$

- Wiederhole ab Schritt 3 für ein Item:

$$q_i = \left(\sum_{u':r_{u'i} \neq \emptyset} p_{u'} p_{u'}^T + \lambda 1_{k \times k} \right)^{-1} \sum_{\bar{u}:r_{\bar{u}i} \neq \emptyset} p_{\bar{u}} r_{\bar{u}i}$$

Aufgabe: Skalierbarkeit

- Die Update-Regel

$$p_u = \left(\sum_{i' : r_{ui'} \neq \emptyset} q_{i'} q_{i'}^T + \lambda 1_{k \times k} \right)^{-1} \sum_{\bar{i} : r_{u\bar{i}} \neq \emptyset} q_{\bar{i}} r_{u\bar{i}}$$

- Funktioniert wunderbar auf Spark! Annahmen:
  - r ist sparse
  - k ist sehr klein (z.B. k=5)
- Welche Daten müssen über das Netzwerk geschickt werden?
- Wie sollen die Daten auf den Nodes Verteilt werden, damit die Berechnung effizient wird?