



Textklassifikation mit Naive Bayes

Naive Bayes Text Classification



- Anwendungen
 - Spam-Nonspam
 - Welcher Autor schrieb welches Dokument?
 - Männlicher/weiblicher AutorIn?

- Textklassifikation:

- Input: Dokument d;
 - Output: Eine der Klassen c_1, c_2, \dots, c_j

- Bag of Words-Darstellung:

- Naive Bayes:

```
x love xxxxxxxxxxxxxxxx sweet
xxxxxxxx satirical xxxxxxxx
xxxxxxxx great xxxxxxxx
xxxxxxxxxxxxxxxx fun xxxx
xxxxxxxxxxxxxxxx whimsical xxxx
romantic xxxx laughing
xxxxxxxxxxxxxxxxxxxxxxxxxxxx
xxxxxxxxxxxxxxxx recommend xxxxx
xxxxxxxxxxxxxxxxxxxxxxxxxxxx
xx several xxxxxxxxxxxxxxxx
xxxx happy xxxxxxxx again
xxxxxxxxxxxxxxxxxxxxxxxxxxxx
xxxxxxxxxxxxxxxxxxxxxxxxxxxx
```



great	2
love	2
recommend	1
laugh	1
happy	1
...	...

$$P(c|d) = \frac{P(d|c)P(c)}{P(d)}$$



Bayes-Regel

- Benutze Bayes-Regel: [video 1](#), [video 2](#), [video 3](#)
- Maximum a posteriori Klasse

$$\begin{aligned}c_{MAP} &= \operatorname{argmax}_{c \in C} P(c | d) \\&= \operatorname{argmax}_{c \in C} \frac{P(d | c)P(c)}{P(d)} \\&= \operatorname{argmax}_{c \in C} P(d | c)P(c)\end{aligned}$$



Klassifizieren nach Bayes

- Bestimme wahrscheinlichste Klasse:

$$\begin{aligned}c_{MAP} &= \operatorname{argmax}_{c \in C} P(d | c)P(c) \\ &= \operatorname{argmax}_{c \in C} P(x_1, x_2, \dots, x_n | c)P(c)\end{aligned}$$

- $P(c)$: Wahrscheinlichkeit der Klasse (über alle Dokumente)
- Dokument besteht aus Features **unabhängigen** x_1, \dots, x_n

$$P(x_1, x_2, \dots, x_n | c) = P(x_1 | c)P(x_2 | c) \cdots P(x_n | c)$$

- Für jede Klasse: $P(x_i | c)$: Wahrscheinlichkeit der Anwesenheit von Wort i

$$P(x_1, x_2, \dots, x_n | c) = P(x_1 | c)P(x_2 | c) \cdots P(x_n | c)P(c)$$



- Zähler: Wie oft kommt Wort w_i in Klasse c vor?

$$P(w_i|c) = \frac{\text{count}(w_i, c)}{\sum_{w \in V_{\text{ok}}} \text{count}(w, c)}$$

- Nenner: Wie viele Wörter enthält Klasse c (Anzahl Wörter in Spam-Dokumenten)
- Insgesamt: Welcher Bruchteil aller Wörter aller Dokumente der Klasse c hat das Wort w_i ?
 - Mega-Dokument aller Dokumente, welche zur Klasse c gehören
 - Häufigkeit des Wortes w_i / Anzahl Worte im Mega-Dokument



■ Problem bei $P(w_i|c) = 0$

$$c_{MAP} = \arg \max_c \hat{P}(c) \prod_i \hat{P}(x_i|c) = 0$$

$$P(w_i|c) = \frac{\text{count}(w_i, c)}{\sum_{w \in V_{ok}} \text{count}(w, c)}$$



„Add-1-Smoothing!“

$$P(w_i|c) = \frac{\text{count}(w_i, c) + 1}{\sum_{w \in V_{ok}} (\text{count}(w, c) + 1)}$$



Kochrezept

- 1. Erstelle ein Vokabular aller möglicher Wörter
- 2. Berechne $P(c_j)$ für alle Klassen aus dem Trainingsset

$$P(c) = \frac{\text{Anz. Dok in Klasse } c}{\text{Anz. Dok}}$$

- 3. Für jede Klasse c erstelle Mega-Dokument aller Dokumente der Klasse c : $\text{text}(c)$
- 4. Für das Wort w_i in Klasse c :

$$P(w_i|c) = \frac{\text{count}(w_i, c) + 1}{\sum_{w \in \text{Vok}} (\text{count}(w, c) + 1)}$$

D.h. (Wie oft tritt Wort w_i in $\text{text}(c)$ auf +1) / (Anzahl Wörter in $\text{text}(c)$ + Anzahl Wörter in Vokabular)

Kochrezept 2



- 5. Berechne das Klassenlabel

$$c_{MAP} = \arg \max_c \hat{P}(c) \prod_i \hat{P}(x_i|c)$$

- $\arg \max$ ist die Funktion, die jenes c zurück gibt, für welches der Ausdruck rechts davon maximal ist

Beispiel Wetterdaten



- Wird der Ausflug dieses Jahr stattfinden? Bisher galt:

Aussicht	Temp	Feuchtigkeit	Wind	Ausflug findet statt
Sonne	Heiss	Hoch	FALSCH	Nein
Sonne	Heiss	Hoch	WAHR	Nein
Bewölkt	Heiss	Hoch	FALSCH	Ja
Regen	Mild	Hoch	FALSCH	Ja
Bewölkt	Mild	Hoch	FALSCH	Ja
Bewölkt	Kühl	Normal	WAHR	Ja
Sonne	Mild	Normal	WAHR	Nein
Sonne	Mild	Normal	FALSCH	Ja
Sonne	Mild	Normal	FALSCH	Ja
Regen	Kühl	Normal	WAHR	Ja
Regen	Kühl	Normal	WAHR	Ja
Regen	Kühl	Hoch	FALSCH	Nein
Bewölkt	Heiss	Normal	FALSCH	Ja
Regen	Mild	Hoch	WAHR	Nein

Zielvariable

- Dieses Jahr gilt: Es ist sonnig bei kühlen Temperaturen, Es ist feucht und windig

Sonne	Kühl	Hoch	WAHR	?
-------	------	------	------	---



Beispiel Wetterdaten

- „Vokabular“, Features: x_1 =Aussicht, x_2 =Temp, x_3 =Feuchtigkeit, x_4 =Wind
- Satz von Bayes:

$$P(\text{Ja}|x) = \frac{P(x|\text{Ja})P(\text{Ja})}{P(x)}$$

$$P(\text{Nein}|x) = \frac{P(x|\text{Nein})P(\text{Nein})}{P(x)}$$

- **Wähle „Ja“, wenn $P(\text{Ja}|x) > P(\text{Nein}|x)$, sonst „Nein“**
- $P(x)$ spielt dafür keine Rolle
- Wie gross ist
 - $P(\text{Ja})$
 - $P(\text{Nein})$

?

Ausflug findet statt
Nein
Nein
Ja
Ja
Ja
Ja
Nein
Ja
Ja
Ja
Ja
Nein
Ja
Nein



Beispiel Wetterdaten

- „Vokabular“, Features: x_1 =Aussicht, x_2 =Temp, x_3 =Feuchtigkeit, x_4 =Wind
- Satz von Bayes:

$$P(\text{Ja}|x) = \frac{P(x|\text{Ja})P(\text{Ja})}{P(x)}$$

$$P(\text{Nein}|x) = \frac{P(x|\text{Nein})P(\text{Nein})}{P(x)}$$

- $P(\text{Ja}) = 9/14$
- $P(\text{Nein}) = 5/14$
- **Wie gross ist $P(x|\text{Ja})$?**

Zielvariable

Ausflug findet statt
Nein
Nein
Ja
Ja
Ja
Ja
Nein
Ja
Ja
Ja
Ja
Nein
Ja
Nein

- Insbesondere für $x =$

Sonne	Kühl	Hoch	WAHR
-------	------	------	------



Beispiel Wetterdaten

- Featurevektor x : x_1 =Aussicht, x_2 =Temp, x_3 =Feuchtigkeit, x_4 =Wind
- Likelihood (=“Wahrscheinlichkeit der Daten“ x)

$$\begin{aligned} P(x|\text{Ja}) &= P(x_1, x_2, x_3, x_4|\text{Ja}) \\ &= P(x_1|\text{Ja}) \cdot P(x_2|\text{Ja}) \cdot P(x_3|\text{Ja}) \cdot P(x_4|\text{Ja}) \end{aligned}$$

- Welche Bedingung/Annahme erlaubte diesen Schritt?
- Wie berechnen wir nun z.B.

$$P(x_1|\text{Ja})$$

?

- Insbesondere für $x_1 =$ Sonne



Beispiel Wetterdaten

- Hilfreich zur Berechnung von $P(x_1 | \text{Ja})$

x_1 x_2 x_3 x_4

Aussicht	Temp	Feuchtigkeit	Wind	Ausflug findet statt
Sonne	Heiss	Hoch	FALSCH	Nein
Sonne	Heiss	Hoch	WAHR	Nein
Bewölkt	Heiss	Hoch	FALSCH	Ja
Regen	Mild	Hoch	FALSCH	Ja
Bewölkt	Mild	Hoch	FALSCH	Ja
Bewölkt	Kühl	Normal	WAHR	Ja
Sonne	Mild	Normal	WAHR	Nein
Sonne	Mild	Normal	FALSCH	Ja
Sonne	Mild	Normal	FALSCH	Ja
Regen	Kühl	Normal	WAHR	Ja
Regen	Kühl	Normal	WAHR	Ja
Regen	Kühl	Hoch	FALSCH	Nein
Bewölkt	Heiss	Normal	FALSCH	Ja
Regen	Mild	Hoch	WAHR	Nein



Aussicht	Ja	Nein
Sonne	2	3
Bewölkt	4	0
Regen	3	2

Temp	Ja	Nein
Heiss	2	2
Mild	4	2
Kühl	3	1

Feucht	Ja	Nein
Hoch	3	4
Normal	6	1

Wind	Ja	Nein
WAHR	3	3
FALSCH	6	2



$P(x|c)$

- Bedingte Wahrscheinlichkeiten $P(x_1|c_1)$

■ Für x=	Sonne	Kühl	Hoch	WAHR
----------	-------	------	------	------

Aussicht	Ja	Nein	
Sonne	2	3	$P(. Sonne)$
Bewölkt	4	0	$P(. Bewölkt)$
Regen	3	2	$P(. Regen)$
	$P(. Ja)$	$P(. Nein)$	

Aufgabe 1:

- $P(Sonne|Ja) = ?$
- $P(Bewölkt|Nein) = ?$
- $P(Ja|Regen) = ?$



$P(x|c)$

- Bedingte Wahrscheinlichkeiten $P(x_1|c_1)$

Aussicht	Ja	Nein
Sonne	2	3
Bewölkt	4	0
Regen	3	2

- $P(\text{Sonne}|\text{Ja}) = 2/9$
- $P(\text{Bewölkt}|\text{Nein}) = 0/5 = 0$
- $P(\text{Ja}|\text{Regen}) = 3/5$



Beispiel Wetterdaten

- Zur Erinnerung: $x =$

Sonne	Kühl	Hoch	WAHR
-------	------	------	------

- $$P(x|Ja) = P(x_1, x_2, x_3, x_4|Ja)$$
$$= P(x_1|Ja) \cdot P(x_2|Ja) \cdot P(x_3|Ja) \cdot P(x_4|Ja)$$

- Gesucht ist u.a. $P(x_1|Ja)$

- $P(\text{sonnig}|Ja) = ?$
 $P(\text{kühl}|Ja) = ?$
 $P(\text{Hoch}|Ja) = ?$
 $P(\text{WAHR}|Ja) = ?$

Aussicht	Ja	Nein
Sonne	2	3
Bewölkt	4	0
Regen	3	2

Temp	Ja	Nein
Heiss	2	2
Mild	4	2
Kühl	3	1

Feucht	Ja	Nein
Hoch	3	4
Normal	6	1

Wind	Ja	Nein
WAHR	3	3
FALSCH	6	2



Likelihood $P(x|Ja)$

- Zur Erinnerung: $x =$

Sonne	Kühl	Hoch	WAHR
-------	------	------	------
- $P(x|Ja) = P(x_1, x_2, x_3, x_4|Ja)$
 $= P(x_1|Ja) \cdot P(x_2|Ja) \cdot P(x_3|Ja) \cdot P(x_4|Ja) \cdot P(Ja)$
- Gesucht ist u.a. $P(x_1|Ja)$
- $P(\text{sonnig}|Ja) = 2/9$
 $P(\text{kühl}|Ja) = 3/9$
 $P(\text{Hoch}|Ja) = 3/9$
 $P(\text{WAHR}|Ja) = 3/9$
- Also insgesamt

$$P(x|Ja) = \frac{2}{9} \cdot \frac{3}{9} \cdot \frac{3}{9} \cdot \frac{3}{9} = 0.0082$$

Aussicht	Ja	Nein
Sonne	2	3
Bewölkt	4	0
Regen	3	2

Temp	Ja	Nein
Heiss	2	2
Mild	4	2
Kühl	3	1

Feucht	Ja	Nein
Hoch	3	4
Normal	6	1

Wind	Ja	Nein
WAHR	3	3
FALSCH	6	2



Likelihood $P(x|\text{Nein})$

■ Zur Erinnerung: $x =$

Sonne	Kühl	Hoch	WAHR
-------	------	------	------

■
$$P(x|\text{Nein}) = P(x_1|\text{Nein}) \cdot P(x_2|\text{Nein}) \\ \cdot P(x_3|\text{Nein}) \cdot P(x_4|\text{Nein}) \\ \cdot P(\text{Nein})$$

■ $P(\text{Nein}) = 5/14$

■
$$\begin{aligned} P(\text{sonnig}|\text{Nein}) &= ? \\ P(\text{kühl}|\text{Nein}) &= ? \\ P(\text{Hoch}|\text{Nein}) &= ? \\ P(\text{WAHR}|\text{Nein}) &= ? \end{aligned}$$

Aussicht	Ja	Nein
Sonne	2	3
Bewölkt	4	0
Regen	3	2

Temp	Ja	Nein
Heiss	2	2
Mild	4	2
Kühl	3	1

Feucht	Ja	Nein
Hoch	3	4
Normal	6	1

Wind	Ja	Nein
WAHR	3	3
FALSCH	6	2



Beispiel Wetterdaten

- Zur Erinnerung: $x =$

Sonne	Kühl	Hoch	WAHR
-------	------	------	------

- $$\begin{aligned} P(\text{Nein}|x) &= P(x|\text{Nein}) \frac{P(\text{Nein})}{P(x)} \\ &= P(x_1|\text{Nein}) \cdot P(x_2|\text{Nein}) \\ &\quad \cdot P(x_3|\text{Ja}) \cdot P(x_4|\text{Ja}) \cdot \frac{P(\text{Nein})}{P(x)} \end{aligned}$$

- $P(\text{Nein}) = 5/14$

- $$\begin{aligned} P(\text{sonnig}|\text{Nein}) &= 3/5 \\ P(\text{kühl}|\text{Nein}) &= 1/5 \\ P(\text{Hoch}|\text{Nein}) &= 4/5 \\ P(\text{WAHR}|\text{Nein}) &= 3/5 \end{aligned}$$

- $$P(x|\text{Nein}) = \frac{3}{5} \cdot \frac{1}{5} \cdot \frac{4}{5} \cdot \frac{3}{5} = 0.0576$$

- $$P(\text{Nein}|x) = P(x|\text{Nein}) \frac{P(\text{Nein})}{P(x)} = \frac{0.0206}{P(x)}$$

Aussicht	Ja	Nein
Sonne	2	3
Bewölkt	4	0
Regen	3	2

Temp	Ja	Nein
Heiss	2	2
Mild	4	2
Kühl	3	1

Feucht	Ja	Nein
Hoch	3	4
Normal	6	1

Wind	Ja	Nein
WAHR	3	3
FALSCH	6	2



Klassenzuordnung

- $P(\text{Ja}|x)$:

- $P(\text{Ja}) = 9/14$

- $P(x|\text{Ja}) = \frac{2}{9} \cdot \frac{3}{9} \cdot \frac{3}{9} \cdot \frac{3}{9} = 0.0082$

- $P(\text{Ja}|x) = P(x|\text{Ja}) \frac{P(\text{Ja})}{P(x)} = 0.0053/P(x)$

- $P(\text{Nein}|x)$:

- $P(\text{Nein}) = 5/14$

- $P(x|\text{Nein}) = \frac{3}{5} \cdot \frac{1}{5} \cdot \frac{4}{5} \cdot \frac{3}{5} = 0.0576$

- $P(\text{Nein}|x) = P(x|\text{Nein}) \frac{P(\text{Nein})}{P(x)} = 0.0206/P(x)$

- **$P(\text{Nein}|x)$ ist grösser als $P(\text{Ja}|x)$, daher klassieren wir**

Sonne	Kühl	Hoch	WAHR
-------	------	------	------



Nein